Victor de Lima Wang

EcoVision Iterativo: Aprimorando a Triagem de Resíduos Automaticamente

São Paulo, SP

2026

Victor de Lima Wang

EcoVision Iterativo: Aprimorando a Triagem de Resíduos Automaticamente

Trabalho de conclusão de curso apresentado ao Departamento de Engenharia de Computação e Sistemas Digitais da Escola Politécnica da Universidade de São Paulo para obtenção do Título de Engenheiro.

Universidade de São Paulo – USP

Escola Politécnica

Departamento de Engenharia de Computação e Sistemas Digitais (PCS)

Orientador: Prof. Dr. Artur Jordão Lima Correia

São Paulo, SP

2026

Resumo

Palavras-chave: Visão Computacional, Inteligência Artificial, Coleta Seletiva, Aprendizado Ativo.

Abstract

Keywords: Computer Vision. Artificial Intelligence. Waste Sorting. Active Learning.

Lista de ilustrações

Figura 1 – Diagrama Funcional de *EcoVision* 23
Figura 2 – Diagrama de blocos funcionais do *EcoVision*. 24
Figura 3 – Visualização em *SketchUp* da maquete preliminar. 24

Lista de tabelas

Tabela 1 – Pesos do YOLO no repositório. 26
Tabela 2 – Benchmark dos pesos TACO sem fine-tuning, por cenário. P média é `metrics.box.mp` do Ultralytics. 27
Tabela 3 – Métricas de validação dos checkpoints com fine-tuning (YOLOv8s). . . 27
Tabela 4 – Requisitos funcionais. 32
Tabela 5 – Requisitos não funcionais. 33

Lista de abreviaturas e siglas

IA	Inteligência Artificial
RF	Requisitos Funcionais
RFN	Requisitos Não Funcionais
TACO	Trash Annotations in Context
USB	Universal Serial Bus
YOLO	You Only Look Once

Sumário

1 INTRODUÇÃO . . . 13
1.1 Motivação . . . 13
1.1.1 Produção de Resíduos Sólidos no Brasil . . . 13
1.1.2 Automação de Triagem . . . 14
1.2 Objetivos . . . 14
1.3 Justificativa . . . 15
1.4 Organização do Trabalho . . . 15

2 ASPECTOS CONCEITUAIS . . . 17
2.1 Triagem de Resíduos . . . 17
2.1.1 Tratamento de Resíduos e Coletivas no Brasil . . . 17
2.1.2 Triagem Automatizada de Materiais em Esteira . . . 18
2.2 Visão de Máquina . . . 19
2.2.1 Tarefas de Visão . . . 19
2.2.2 Redes Neurais Convolucionais (CNN) . . . 19
2.2.2.1 You Only Look Once (YOLO) . . . 20

3 METODOLOGIA . . . 21

4 PROJETO ANTERIOR: ECOVISION . . . 23
4.1 Descrição Funcional . . . 23
4.2 Arquitetura, Componentes e Maquete . . . 24
4.2.1 Modelo de detecção . . . 25
4.2.1.1 Pesos disponíveis . . . 25
4.2.1.2 Uso do modelo no sistema . . . 25
4.3 Resultados e Avaliação . . . 26
4.3.1 Modelos pré-treinados (só TACO) nas fotos da equipe . . . 26
4.3.2 Modelos com fine-tuning . . . 27
4.3.3 Sistema completo . . . 27
4.4 Limitações . . . 28
4.4.1 Modelo e dados . . . 28
4.4.2 Sistema . . . 28

5 ESPECIFICAÇÃO . . . 29
5.1 Descrição Funcional . . . 29
5.1.1 Atores . . . 29

5.1.2 Módulos 30
5.1.3 Protótipo físico 30
5.2 Requisitos 31
5.2.1 Requisitos Funcionais 31
5.2.2 Requisitos Não Funcionais 31
5.3 Considerações sobre o Novo Modelo de Detecção 31
5.3.1 Ponto de Partida 31
5.3.2 Taxonomia Hierárquica de Classes 31
5.3.3 Escolha do Detector 34
5.3.4 Anotação Assistida 34
5.3.5 Protocolo de Avaliação 35

6 IMPLEMENTAÇÃO 37

7 RESULTADOS 39

8 CONCLUSÕES 41

REFERÊNCIAS 43

1 Introdução

O tratamento adequado de resíduos sólidos urbanos é um dos grandes desafios do Brasil. Em especial, a reciclagem requer triagem, a separação e classificação do eficiente de material, que pode ser realizada por separação na fonte e coleta seletiva, mas também por divisão pós-coleta, feito usualmente manualmente por coletivas e catadores. Nesse contexto, identificamos a necessidade de sistemas que possam auxiliar o processo de triagem nessas estações, com objetivo de aumentar a eficiência da separação e o volume de processamento.

Neste trabalho, apresentamos o projeto *EcoVision Iterativo*, desenvolvido a partir da plataforma anterior *EcoVision* (SANTOS; COSTA, 2025). Este trabalho busca tratar limitações dos resultados anteriores, com o foco na melhoraria da precisão da detecção de resíduos, utilizando técnicas de anotação assistida para o desenvolvimento de um banco de dados incremental e então treinamento iterativo do modelo de detecção. Tratamos também outras restrições da implementação anterior, como alta latência da detecção e armazenamento de *logs* de detecção.

Nas seções a seguir, detalhamos a motivação, objetivos, justificativa e organização deste trabalho.

1.1 Motivação

1.1.1 Produção de Resíduos Sólidos no Brasil

Segundo Brasil (2010), dentre os processos de gestão de resíduos sólidos urbanos (RSU), as formas de tratamento seguem a priorização: reutilização; reciclagem; tratamento dos resíduos sólidos; e disposição final ambientalmente adequada. Em 2024, o Brasil gerou 81,6 milhões de toneladas de RSU. Desse total de resíduos, 51,9% teve disposição final adequada em aterros sanitários e apenas 8.7% do material foi enviado para reciclagem, por meio da coleta informal e das unidades de triagem de recicláveis (ABREMA, 2025). Justifica-se o baixo volume de RSU reciclados por limitações das próprias usinas de triagem. A separação usualmente totalmente manual sofre de eficiência, somada às dificuldades de remuneração e aos gastos com materiais com baixa viabilidade econômica, as coletivas sofrem de limitações estruturais(Instituto Caminhos Sustentáveis, 2024).

Nesse contexto, identificamos a necessidade de equipamentos que possam automatizar processos da triagem, aumentando o volume de processamento de resíduos e a rentabilidade do processo.

1.1.2 Automação de Triagem

A automação de triagem por meio de sensores óticos e visão computacional é objeto de pesquisa já discutido (GUNDUPALLI; HAIT; THAKUR, 2017; LU; CHEN, 2022). e existem soluções comerciais de grande porte. A empresa TOMRA, por exemplo, apresenta o equipamento GAINnext, esteira com equipamento integrado com múltiplos sensores e aprendizado profundo para classificar múltiplas classes de objetos, mesmo quando sobrepostos (TOMRA, 2026). Esse tipo de sistema, porém, não se mostra viável para cooperativas no Brasil, que ainda carecem de investimentos para a compra deste tipo de equipamento especializado (Instituto Caminhos Sustentáveis, 2024).

O uso de IA para detecção em tempo real se tornou viável com os avanços em detecção de objetos com redes neurais profundas, que possibilitaram a identificação de resíduos em tempo real com hardware de custo moderado (REDMON et al., 2016). Esses modelos, porém, dependem de conjuntos de dados representativos do ambiente de operação para a inferência correta de objetos. Conjuntos públicos como TrashNet (YANG; THUNG, 2016) e TACO (PROENçA; SIMõES, 2020) foram capturados em condições distintas das de uma esteira de triagem, e mesmo conjuntos coletados em esteiras reais, como o ZeroWaste (BASHKIROVA et al., 2022), explicitam a dificuldade imposta por oclusão e deformação dos objetos. Adicionalmente, a composição dos resíduos varia espacialmente e temporalmente, dependendo respectivamente da origem e período de geração do resíduo gerado, portanto inferimos que um modelo treinado uma única vez tende a se desatualizar.

Dessa forma, reconhecemos a busca por sistemas de triagem de baixo custo capazes de ampliar continuamente seu conjunto de dados a partir da própria operação, adaptando-se à composição local e temporal dos resíduos.

1.2 Objetivos

O trabalho tem como objetivo incrementar o projeto Ecovision, sistema de detecção de resíduos em esteira em movimento baseado em visão computacional, avaliando se as mudanças propostas afetam positivamente a precisão de detecção e demais limitações, o aproximando de uma plataforma viável para uso.

A principal proposta de melhoria do *EcoVision Iterativo* é implementação de um ciclo de aprimoramento por meio de: coleta de imagens durante a operação; anotação assistida por modelos de alta precisão de IA; e retreinamento de modelo de detecção em tempo real. Isso caracteriza uma abordagem com humano no laço (*human-in-the-loop*) (MONARCH, 2021) relacionada ao aprendizado ativo (SETTLES, 2010; REN et al., 2021). Esse ciclo visa melhorar a precisão de detecção de objetos para auxiliar operados de separação e produzir, como subproduto do uso do sistema, um conjunto de dados de resíduos representativo do ambiente de operação, evitando o custo de anotação totalmente

manual.

Para isso, planeja-se a execução das tarefas apresentadas a seguir:

1. Analisar e reprojetar a maquete do protótipo original EcoVision para identificar e resolver limitações físicas;
2. Reestruturar o módulo de software para implementar correções e capturar de imagens para anotação assistida de resíduos e monitoramento do histórico de resíduos passados;
3. Implementar o fluxo de retreinamento anotação assistida, quantificando precisão de anotação e a redução do tempo de anotação por volume de imagens;
4. Avaliar o desempenho do detector ao longo de ciclos de retreinamento.

1.3 Justificativa

Não identificamos nenhuma solução efetiva e acessível para o problema de triagem de resíduos sólido por coletivas, mesmo o projeto anterior ainda não se provou viável (SANTOS; COSTA, 2025). Dentre as limitações estão: a imprecisão na detecção dos resíduos, atribuída a baixa quantidade de dados no conjunto de dados; a separação descompassada, devido a questões de latência; e detecções múltiplas para um mesmo resíduo, provocando acionamentos indevidos. Acreditamos, porém, no potencial da tecnologia, e portanto queremos tratar essas limitações e os outros pontos de menor escopo, com maior foco em viabilizar o uso do projeto como auxílio à identificação de resíduos de interesse à estação de triagem, para melhor eficiência do processamento de resíduos.

1.4 Organização do Trabalho

O trabalho a seguir está organizado por: Capítulo 2 apresenta a fundamentação teórica sobre gestão de resíduos, detecção de objetos, aprendizado ativo e classificação hierárquica, além dos trabalhos relacionados; Capítulo 3 discute os métodos de especificação, projeto e avaliação; Capítulo 4 descreve o projeto *EcoVision Evolution* e analisa suas limitações; Capítulo 5 especifica as melhorias propostas; Capítulo 6 detalha a implementação do sistema; Capítulo 7 apresenta a metodologia de avaliação e os resultados obtidos; e por fim, Capítulo 8 discute as conclusões, limitações e trabalhos futuros.

2 Aspectos Conceituais

Este capítulo apresenta os conceitos necessários para o melhor entendimento da especificação, implementação e avaliação do projeto. Para isso, contextualizamos a triagem de materiais Seção 2.1, detalhamos a teoria de IA e visão de máquina na Seção 2.2 e apresentamos os fundamentos de aprendizado contínuo considerados para a evolução incremental do modelo.

2.1 Triagem de Resíduos

Detalhamos a seguir o funcionamento das coletivas, tecnologias de sensoriamento e atuação e soluções comerciais existentes, apresentados em suas respectivas subseções. Julgamos que o entendimento desse contexto foi importante para especificação de um projeto relevante e ético.

2.1.1 Tratamento de Resíduos e Coletivas no Brasil

A Brasil (2010) define a ordem de prioridade de tratamentos adequado de RSU: reutilização; reciclagem; tratamento dos resíduos sólidos; e disposição final ambientalmente adequada dos rejeitos. Para o direcionamento de um material para usinas de reciclagem há dois caminhos possíveis: ou este resíduo é coletado por catadores informais e entregado diretamente; ou é coletado por serviço público e então encaminhado para usinas de triagem. Ou seja, quando recolhido por meios de coleta seletiva e separação na origem resíduos coletados via serviços públicos dependem das centrais de triagem (ABREMA, 2025).

Centrais de triagem são representadas principalmente por organizações de catadores, cooperativas e associações que comercializam resíduos, destinando-os a reciclagem. Essas organizações sofrem de dificuldades de remuneração, e de coletores e funcionários, e infraestrutura, deficiente de equipamentos (Instituto Caminhos Sustentáveis, 2024). Justificam-se esses problemas com uma estrutura pouco administrativa, produtiva, infraestruturalmente madura. Equipamentos essenciais para o aumento da produtividade não são realidade de todas as organizações (Instituto Caminhos Sustentáveis, 2024). Há ainda um problema da própria cadeia, a de materiais pouco rentáveis que acabam por não serem vendidos. Isto é relacionado a baixa viabilidade econômica de certos tipos de materiais, que mesmo sendo tecnicamente viáveis de serem reciclados não são por baixo valor, custos de transporte ou necessidade de grande volume (Instituto Caminhos Sustentáveis, 2024).

A partir dessas informações, reconhecemos alguns requisitos para um projeto cujo objetivo seja auxiliar a eficiência dessas cooperativas e associações:

- Auxiliar a funcionários: auxiliar operadores, sendo preciso e dando suporte sem prejudicar o fluxo de trabalho anterior;

- Alto volume processado: capaz de trabalhar em alta capacidade, preferencialmente aumentando a densidade de resíduos processados por segundo;

- Acessível comercialmente: construído por componentes de baixo custo, de fácil acesso e implementação em fluxos existentes.

2.1.2 Triagem Automatizada de Materiais em Esteira

Gundupalli, Hait e Thakur (2017) dividem as técnicas de triagem automática em direta, que utilizando as propriedades de materiais diretamente para a sua separação, e indireta, que depende de sensores para detectar a presença e localização para a remoção por máquina e robôs. Os autores discutem o fluxo usual para a triagem automática de RSU como: pré-tratamento por para separação de matéria orgânica; comminução de resíduos secos, ou seja a fragmentação para granularidade menores; separação de materiais ferro magnéticos; e por fim, materiais não ferro magnéticos podem ser separados por diversas técnicas indiretas, como por: corrente parasita, óptica, espectroscopia a laser, hiperespectral, entre outras.

Por realizar a separação diretamente da propriedade dos materiais, como densidade, ferromagnetismo, rigidez, é possível obter maior confiança na classificação, porém, essas técnicas requerem estrutura e equipamentos físicos como trituradores, imãs industriais, prensa parafuso, hidrociclones. Já a detecção indireta, é representada por sensores, unidade de processamento e uma atuador, um jato de ar, por exemplo (GUNDUPALLI; HAIT; THAKUR, 2017).

Gundupalli, Hait e Thakur (2017) identificam que países em desenvolvimento usualmente não implementam técnicas separação na coleta de forma generalizada, gerando o problema de gerenciamento de resíduos de materiais misturados. Além disso, reconhecem a necessidade de equipamentos de baixo custo para a aceitação da tecnologia nestes países.

Reconhecemos que tanto as técnicas de separação direta e as técnicas mais precisas de separação indireta são eficiente no tratamento de objetos, porém alguns equipamentos, sensores e estruturas podem não ser facilmente acessíveis para as associações de coleta do Brasil. Com essas considerações, descrevemos o presente trabalho como um sistema de separação indireta óptico genérico, no qual os sensores são uma câmera e o operador de esteira, este atuando também como atuador em conjunto com um servomotor.

2.2 Visão de Máquina

A visão computacional é a área que trata da extração de informação a partir de imagens digitais (SZELISKI, 2022). Até o início da década de 2010, sistemas de reconhecimento visual dependiam de características projetadas manualmente, como descritores de bordas e gradientes, combinadas a classificadores treinados. Essa abordagem foi amplamente substituída por redes neurais profundas, que aprendem as características diretamente dos dados (GOODFELLOW; BENGIO; COURVILLE, 2016). Esta seção apresenta os conceitos dessas redes necessários à compreensão do detector empregado neste trabalho.

2.2.1 Tarefas de Visão

Três tarefas de reconhecimento são relevantes para a triagem de resíduos, diferenciadas pela saída que produzem (SZELISKI, 2022):

- **Classificação de imagens**: atribui um único rótulo à imagem inteira. Pressupõe, portanto, um objeto dominante por imagem.
- **Detecção de objetos**: para cada objeto presente, produz uma caixa delimitadora (*bounding box*), um rótulo de classe e um escore de confiança. Admite um número variável de objetos por imagem.
- **Segmentação de instâncias**: além da classe, associa a cada objeto uma máscara que indica, pixel a pixel, a região que ele ocupa.

Em uma esteira de triagem, vários itens podem estar simultaneamente no campo de visão da câmera, o que exclui a classificação de imagens como formulação principal. Entre detecção e segmentação, este trabalho adota a detecção. A segmentação seria preferível em cenários com forte sobreposição entre objetos ou quando a área exata do objeto for necessária, como no posicionamento preciso de bicos de ar.

2.2.2 Redes Neurais Convolucionais (CNN)

Uma rede neural profunda é uma composição de funções parametrizadas, organizadas em camadas, cujos parâmetros são ajustados a partir de exemplos rotulados (GOODFELLOW; BENGIO; COURVILLE, 2016). As redes neurais convolucionais (CNNs, do inglês *convolutional neural networks*) especializam essa ideia para dados com estrutura espacial, como imagens (LECUN et al., 1998).

O treinamento consiste em minimizar uma função de perda $\mathcal{L}$, que quantifica a discrepância entre as predições da rede e os rótulos, sobre um conjunto de treinamento. Os gradientes de $\mathcal{L}$ em relação aos parâmetros são calculados por retropropagação e usados por

um otimizador baseado em gradiente descendente estocástico, que atualiza os parâmetros a cada lote de exemplos (GOODFELLOW; BENGIO; COURVILLE, 2016). A normalização em lote (*batch normalization*) (IOFFE; SZEGEDY, 2015) estabiliza e acelera esse processo e está presente em praticamente todas as arquiteturas atuais.

Historicamente, distinguem-se duas famílias. Os detectores de **dois estágios**, cujo representante mais difundido é o Faster R-CNN (REN et al., 2015), primeiro geram um conjunto de regiões candidatas a conter objetos e depois classificam e refinam cada uma. Os detectores de **estágio único**, como o YOLO (REDMON et al., 2016) e o SSD (LIU et al., 2016), predizem caixas e classes diretamente sobre uma grade densa de posições, em uma única passagem pela rede. Os detectores de estágio único foram concebidos para operação em tempo real, mas inicialmente apresentavam precisão inferior, atribuída em parte ao forte desbalanceamento entre as numerosas posições de fundo e as poucas posições com objetos; a *focal loss*, proposta por Lin et al. (2017), mitiga esse problema reduzindo o peso dos exemplos fáceis na função de perda. Com esse e outros avanços, a diferença de precisão entre as famílias foi amplamente reduzida, e detectores de estágio único tornaram-se a escolha predominante em aplicações com restrição de latência.

2.2.2.1 You Only Look Once (YOLO)

O YOLO (*You Only Look Once*) (REDMON et al., 2016) tratou a detecção como um problema de regressão única sobre uma grade da imagem. A arquitetura teve diversas versões subsequentes, desenvolvidas por grupos distintos, e parte das versões recentes não foi publicada em artigo revisado por pares. É o caso do YOLOv8 e de seus sucessores, mantidos pela empresa Ultralytics e documentados apenas em repositório de código e documentação técnica (JOCHER et al.,). Este trabalho utiliza o modelo YOLOv8n da biblioteca Ultralytics.

Na versão YOLOv8, o *backbone* é composto por blocos convolucionais com conexões parciais entre estágios, inspirados na CSPNet (WANG et al., 2020), e termina em um módulo de *pooling* espacial piramidal que agrega contexto em múltiplas escalas. O *neck* segue a estrutura FPN/PANet, e a *head* é *anchor-free* e desacoplada, com ramos separados para regressão de caixas e classificação, produzindo predições em três escalas. Durante o treinamento, as predições são associadas aos objetos anotados por um critério que combina o escore de classificação e a sobreposição da caixa (FENG et al., 2021). A função de perda combina uma entropia cruzada binária para a classificação com duas parcelas de regressão: a perda CIoU (ZHENG et al., 2020), que penaliza, além da baixa sobreposição, a distância entre os centros e a diferença de proporção entre as caixas; e a *distribution focal loss* (LI et al., 2020), que modela a posição de cada borda como uma distribuição discreta. A inferência inclui NMS. Os modelos são disponibilizados em escalas crescentes de capacidade (n, s, m, l, x), pré-treinados no conjunto COCO (LIN et al., 2014).

3 Metodologia

Orientamos o desenvolvimento e avaliação deste projeto com base no projeto anterior *Ecovision*. Foram utilizados diretamente os resultados da plataforma anterior (maquete física, componentes eletrônicos, código) como ponto de partida para o novo projeto, possibilitando o foco em novas implementações e comparação direta entre os resultados dos dois projetos.

Primeiro, fizemos uma análise detalhada do Ecovision, com o objetivo de compreender a plataforma, possibilitando o reaproveitamento eficiente do projeto, e explicitar as diferenças entre os projetos, para fins de avaliação e documentação. A documentação e resultados, na forma da monografia final; maquete física; e código, s especificações, implementações, resultados e limitações do projeto são para que seja então possível decidir quais resultados podem ser reaproveitados, explicitar as diferenças entre este projeto e o novo desenvolvimento. Apresentamos o projeto anterior e a correspondente análise no Capítulo 4.

Após esta análise, com o suporte teórico de artigos pesquisados, definimos a nova especificação do projeto, determinando o escopo, descrevendo os requisitos do sistema, explicitando as diferenças para a plataforma anterior. A identificação desses requisitos consta como já concluído, necessitando de correção ou implementação nova.

Dentre as limitações já conhecidas, priorizaremos o ajuste da maquete física, necessária para o funcionamento do sistema como prova de conceito. E então o foco na implementação e avaliação da detecção de materiais, limitação crítica do projeto anterior.

Após avaliação qualitativa de melhoria de performance, buscamos avaliar quantitativamente a precisão dos novos modelos quando comparados com os modelos anteriores e outros de mercado utilizando imagens fixas manualmente auditadas do banco de imagens.

4 Projeto Anterior: EcoVision

O projeto EcoVision consistiu de uma esteira móvel, câmera para detecção, cancela para separação e interface gráfica para monitoramento e configuração (SANTOS; COSTA, 2025). Esta seção apresenta as especificações, implementações e resultados desse sistema. Essa análise permite encontrar pontos de melhoria e posteriormente melhor avaliar o desempenho de *EcoVision Iterativo*. As Seções 4.1, 4.2.1, 4.3, 4.4 apresentam as informações descritas por Santos e Costa (2025).

4.1 Descrição Funcional

Santos e Costa (2025) descreve o sistema como: uma esteira, que movimenta resíduos com velocidade constante; uma câmera que grava os objetos e transmite o vídeo para uma plataforma de processamento; a plataforma utiliza um modelo de visão computacional para classificar os objetos nas categorias plástico, metal, vidro e papelão, enviando os comandos para um controlador; e o controlador comanda uma cancela para separação dos resíduos e a velocidade da esteira. Adicionalmente, as informações referentes a configuração da esteira e da separação e o monitoramento são apresentadas em um módulo de software, interface *user-friendly* executada a plataforma de processamento local. A Figura 1 ilustra a essência dessa descrição funcional.

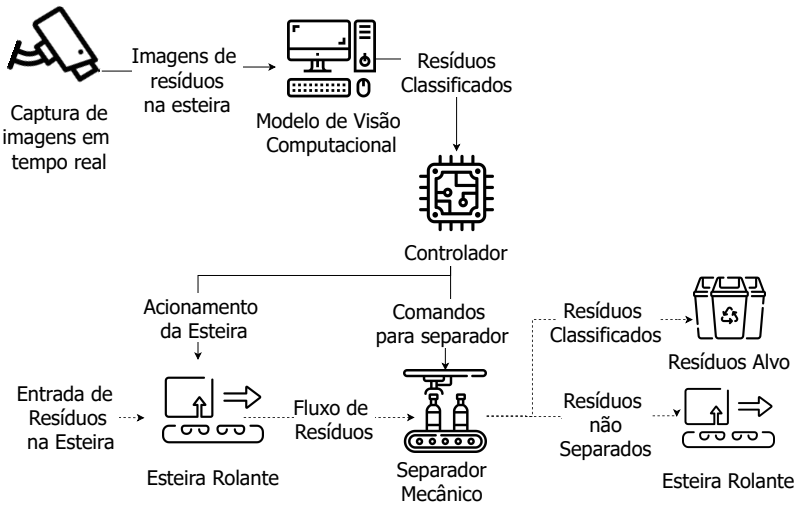


Figura 1 – Diagrama Funcional de *EcoVision*

Fonte: Extraído de Santos e Costa (2025)

4.2 Arquitetura, Componentes e Maquete

Para o protótipo do Ecovision, Santos e Costa (2025) utilizaram: motores de corrente contínua para movimentar a esteira; módulos *driver* ponte H para estes motores; servomotor para a cancela de separação; um computador pessoal móvel como plataforma de execução do modelo de visão; ESP32 para controlar os dispositivos locais; e chapas MDF de 90x60 cm de 6 mm de espessura para construir a maquete física. A Figura 2 apresenta o diagrama de blocos da conexão entre os componentes funcionais.

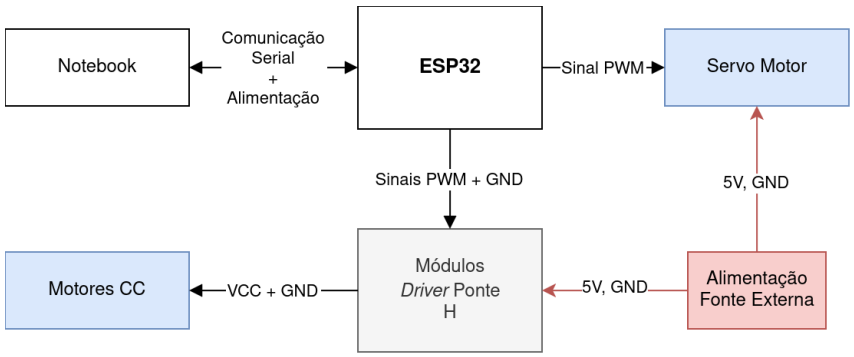


Figura 2 – Diagrama de blocos funcionais do *EcoVision*.

Fonte: Modificado de Santos e Costa (2025)

Conforme Santos e Costa (2025), a maquete do *EcoVision* foi projeta no *software SketchUp*. A versão final incluiu buracos nas quatro pontas superiores para alocar o segundo eixo dos motores de eixo duplo e rasgos nas laterais para ajuste do servomotor e cestas para separação. A Figura 3 apresenta a visualização da maquete preliminar, sem rasgos laterais, no *SketchUp*.

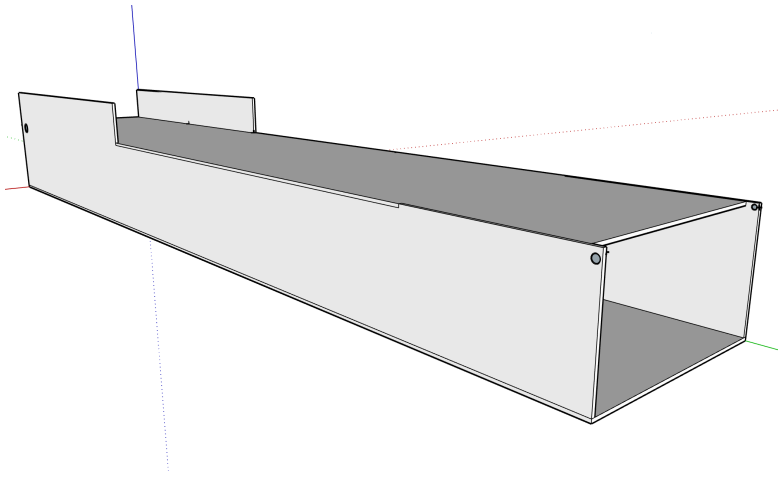


Figura 3 – Visualização em *SketchUp* da maquete preliminar.

Fonte: Extraído de Santos e Costa (2025)

4.2.1 Modelo de detecção

O detector é o YOLOv8 da Ultralytics, um detector de estágio único que prevê caixas e classes diretamente sobre a imagem, adequado a vídeo em tempo real. O ponto de partida são pesos treinados no TACO (*Trash Annotations in Context*), um conjunto de imagens de lixo com 60 categorias. Os modelos com fine-tuning têm 61 classes, as 60 do TACO mais `Background`, com os mesmos IDs do TACO (por exemplo, `5` garrafa plástica transparente, `6` garrafa de vidro, `12` lata de bebida, `17` papelão ondulado, `33` papel comum).

A base própria da equipe tem cerca de 100 fotos de objetos sobre a esteira, anotadas no Roboflow, em quatro cenários de captura:

Cenário	Ângulo da câmera	Flash
`tcc-0CF`	0°	com
`tcc-0SF`	0°	sem
`tcc-45CF`	45°	com
`tcc-45SF`	45°	sem

Os quatro cenários fotografam as mesmas cenas com segundos de diferença: a mesma disposição de objetos, mudando só o ângulo ou o flash. Só o split `validation` de cada cenário está versionado (cerca de 24 imagens e 100 anotações por cenário), concentrado em seis classes: garrafa plástica, tampa plástica, garrafa de vidro, lata de bebida, papelão ondulado e papel comum.

4.2.1.1 Pesos disponíveis

A Tabela 1 lista os pesos dispoíveis no repositório. O backend carrega, por padrão o `best.pt`.

O script de treino, o `data.yaml` e a divisão treino/validação usados no fine-tuning não estão no repositório. Pela monografia, o split foi 80/20 sobre as cerca de 100 fotos.

4.2.1.2 Uso do modelo no sistema

O backend roda o modelo de detecção numa thread e, para cada quadro:

1. converte o nome da classe TACO em um dos quatro materiais por uma tabela explícita (`taco_to_material`). A tabela cobre todas as classes do `best.pt`; classes sem material reciclável definido (resto de comida, sapato, cigarro, *carded blister pack*) vão para `other` e não acionam o servo. A embalagem cartonada (Tetra Pak) é tratada como papel;

Tabela 1 – Pesos do YOLO no repositório.

Arquivo	Descrição
`best.pt`	**Padrão.** YOLOv8s com fine-tuning nas fotos da equipe; continua o `150ep_best.pt` por mais 100 épocas (dez/2025).
`150ep_best.pt`	Fine-tuning do YOLOv8s (`train4`, 200 épocas, batch 4).
`97ep_best.pt`	Fine-tuning do YOLOv8s (`train3`, melhor época 85). Guarda o estado do otimizador (64 MB).
`50ep_best.pt`	Fine-tuning do YOLOv8s (`train2`, 50 épocas).
`yolov8n.pt`, `yolov8m.pt`	Pesos treinados só no TACO (2023), sem fine-tuning; os mesmos arquivos de `legado/yolo_models/taco/`, renomeados.
`yolov8s.pt`	YOLOv8s original do COCO (80 classes: pessoa, carro...), não do TACO, e não detecta lixo. O YOLOv8s do TACO está em `legado/yolo_models/taco/yolov8s_100epochs-best.pt`.

2. quando o centro de uma caixa cai na faixa horizontal da ROI (`roi_y_min` = 0,45 a `roi_y_max` = 0,55 da altura do quadro), envia ao ESP32 o ângulo do material (padrão: plástico 50°, metal 150°, vidro 130°, papel 110°);

3. ignora novas detecções durante `servo_actuation_seconds` (5 s), com um intervalo mínimo fixo de 1,5 s entre disparos;

4. transmite o quadro (JPEG em base64) e as detecções ao frontend por WebSocket.

A esteira não para na detecção. A confiança mínima padrão é 0,35.

4.3 Resultados e Avaliação

4.3.1 Modelos pré-treinados (só TACO) nas fotos da equipe

A versão preliminar comparou YOLOv8n, s e m treinados só no TACO, sem fine-tuning, sobre o split de validação de cada cenário. A Tabela 2 reproduz a planilha gerada.

O YOLOv8s vence em todos os cenários e em todas as métricas, e foi o escolhido para o fine-tuning. O YOLOv8m é pior que o s, o que aponta para diferença de domínio entre o TACO e as fotos da esteira, e para uma amostra pequena, e não para falta de capacidade do modelo. Entre os cenários, os sem flash (SF) tendem a ser melhores que os com flash (CF), e a câmera a 0° tende a ser melhor que a 45° no YOLOv8s.

Tabela 2 – Benchmark dos pesos TACO sem fine-tuning, por cenário. P média é `metrics.box.mp` do Ultralytics.

Modelo	Cenário	mAP@0,5	mAP@0,5:0,95	P média
YOLOv8n	0CF	0,344	0,236	0,300
	0SF	0,400	0,276	0,676
	45CF	0,411	0,285	0,466
	45SF	0,368	0,240	0,402
	média	*0,381*	*0,259*	*0,461*
YOLOv8s	0CF	0,551	0,378	0,652
	0SF	**0,644**	**0,491**	0,755
	45CF	0,507	0,367	0,593
	45SF	0,557	0,364	**0,770**
	média	***0,565***	***0,400***	***0,693***
YOLOv8m	0CF	0,342	0,236	0,455
	0SF	0,396	0,283	0,663
	45CF	0,348	0,252	0,466
	45SF	0,348	0,179	0,530
	média	*0,358*	*0,237*	*0,529*

4.3.2 Modelos com fine-tuning

A Tabela 3 mostra as métricas gravadas nos próprios checkpoints (`train_metrics`), avaliadas no split de validação de cada treino.

Tabela 3 – Métricas de validação dos checkpoints com fine-tuning (YOLOv8s).

Checkpoint	Precisão	Recall	mAP@0,5
`50ep_best.pt`	0,81	0,65	0,71
`97ep_best.pt`	0,75	0,65	0,78
`150ep_best.pt`	0,76	0,75	0,80
`best.pt`	0,82	0,98	0,995

A monografia reporta precisão de cerca de 0,78 e mAP@0,5 de cerca de 0,80, compatíveis com o `150ep_best.pt`. O `best.pt`, usado por padrão, é posterior e continuou o treino sobre o mesmo split.

4.3.3 Sistema completo

Não há resultado quantitativo do sistema em funcionamento: nem taxa de separação correta por material, nem latência entre detecção e acionamento. A monografia mostra a esteira separando metal, plástico e papel numa demonstração, mas sem números. O FPS exibido na interface passou a ser medido em janelas de 1 s na continuação (bc24683); antes era a média desde o início e não refletia o desempenho atual.

4.4 Limitações

4.4.1 Modelo e dados

- **Base pequena e pouco variada:** cerca de 100 fotos, das mesmas cenas, num único ambiente. O modelo tende a não generalizar para outros objetos, fundos ou iluminação.
- **Métricas otimistas** pelo vazamento entre treino e validação. A correção é dividir por cena (agrupando as quatro fotos de cada cena), retreinar e reavaliar.
- **Treino não reprodutível:** faltam o script de treino, o `data.yaml` e o split. Não se sabe se foi usado `freeze` (a monografia diz que só as camadas finais foram treinadas, mas o Ultralytics treina todas por padrão). Os `data.yaml` dos cenários têm um `path:` absoluto do Windows.
- **Classes TACO, não materiais:** o modelo prevê 61 classes e o backend as agrupa em quatro materiais. Erros entre classes do mesmo material não importam, mas classes mistas (*carded blister pack*) ficam sem destino, e a Tetra Pak vai para papel por decisão de projeto.

4.4.2 Sistema

- **O slider de confiança não tem efeito:** `conf` é fixado quando o stream do YOLO começa; a confiança só muda ao reiniciar o backend.
- **O acionamento não acompanha a posição do objeto:** o servo é acionado quando o centro do objeto cruza a ROI e fica 5 s em posição, com a esteira andando. Objetos que chegam nesse intervalo são ignorados, e não há atraso de transporte entre a ROI e o desviador (a distância e a velocidade da esteira não estão documentadas).
- **Sem rastreamento:** a decisão é tomada quadro a quadro, sem IDs de objeto. Um objeto que continue na ROI depois dos 5 s (esteira parada pela interface, por exemplo) dispara de novo, e dois objetos próximos não são distinguidos.
- **Serial sem trava:** a thread do YOLO e o handler do WebSocket escrevem na mesma porta sem lock, e a leitura da resposta bloqueia o laço do WebSocket.
- **Broadcast sem controle de fila:** cada quadro agenda um envio, que se acumulam com um cliente lento.
- **Login simulado:** não há autenticação real.

5 Especificação

Este capítulo especifica as melhorias propostas para o *EcoVision Iterativo* a partir das limitações do projeto anterior, analisadas no Capítulo 4. Apresentamos primeiro a descrição funcional do sistema, depois seus requisitos funcionais e não funcionais e, por fim, as considerações que orientam o projeto do novo modelo de detecção e do ciclo de anotação assistida e retreinamento.

5.1 Descrição Funcional

O *EcoVision Iterativo* mantém a função do sistema anterior: uma câmera filma a esteira, um modelo de detecção identifica os resíduos e um microcontrolador aciona o desviador para encaminhar cada objeto à saída do seu material. A diferença está em que o sistema passa a produzir, durante a operação, os dados necessários para melhorar o próprio modelo. A operação de triagem e o aprimoramento do modelo formam um ciclo, ilustrado pelas etapas a seguir:

1. **Operação:** o detector processa o vídeo da esteira em tempo real, rastreia cada objeto ao longo dos quadros e aciona o desviador uma única vez por objeto, no instante em que ele alcança o ponto de desvio;

2. **Coleta:** durante a operação, o sistema registra cada objeto detectado (classe, confiança, horário, decisão de acionamento) e seleciona quadros para anotação, priorizando os casos em que o detector tem baixa confiança ou discorda do anotador automático;

3. **Anotação assistida:** um anotador automático de vocabulário aberto propõe caixas e rótulos para os quadros selecionados, e um operador humano revisa as propostas, aceitando, corrigindo ou descartando cada uma;

4. **Retreinamento:** com o conjunto de dados ampliado, um novo modelo é treinado fora do laço de operação, sem interromper a triagem;

5. **Avaliação e implantação:** o novo modelo é comparado ao modelo em uso num conjunto de teste fixo e só substitui o anterior se não piorar o desempenho.

5.1.1 Atores

Identificamos três papéis de uso, que podem ser exercidos pela mesma pessoa numa cooperativa pequena:

- **Operador de triagem:** liga e desliga a esteira, acompanha as detecções em tempo real e consulta o histórico de resíduos processados;
- **Revisor de anotações:** revisa as anotações propostas pelo anotador automático e, quando necessário, cadastra novas classes de resíduo;
- **Administrador:** configura o sistema (câmera, porta serial, ângulos do desviador, limiar de confiança), dispara ciclos de retreinamento e decide a implantação de novos modelos.

5.1.2 Módulos

O sistema se divide nos módulos a seguir. Os quatro primeiros correspondem ao sistema anterior, reestruturado; os demais são novos.

Captura e inferência: lê o vídeo da câmera, executa o detector e rastreia os objetos entre quadros;

Controle de acionamento: converte cada objeto rastreado num comando ao desviador, compensando o tempo de transporte entre a região observada e o ponto de desvio;

Firmware: recebe os comandos pela porta serial e controla o servo do desviador e os motores da esteira;

Interface: exibe o vídeo com as detecções, o estado da esteira e da conexão, e as telas de configuração;

Registro: armazena o histórico de objetos detectados e de acionamentos, e as métricas de latência;

Base de dados incremental: armazena os quadros coletados, suas anotações e a versão do modelo que os processou;

Anotação assistida: gera pré-anotações com o anotador automático e oferece ao revisor uma interface de revisão;

Treinamento e versionamento: treina novos modelos a partir da base incremental, avalia-os e mantém o histórico de versões, permitindo voltar a uma versão anterior.

5.1.3 Protótipo físico

A maquete do protótipo anterior é reprojetada para que as condições de captura e de acionamento sejam reprodutíveis: a câmera fica em posição e ângulo fixos, a iluminação da região observada é controlada, a distância entre a região observada e o desviador é

conhecida e a velocidade da esteira é medida. Esses parâmetros alimentam o controle de acionamento e reduzem a variação entre as imagens de treino e as de operação.

5.2 Requisitos

Os requisitos a seguir partem das limitações do projeto anterior (Capítulo 4) e dos objetivos deste trabalho. Os valores marcados como [**a definir**] dependem de medições no protótipo reprojetado, em especial da velocidade da esteira e da distância entre a região observada e o desviador.

5.2.1 Requisitos Funcionais

5.2.2 Requisitos Não Funcionais

5.3 Considerações sobre o Novo Modelo de Detecção

5.3.1 Ponto de Partida

O detector do projeto anterior é um YOLOv8s pré-treinado no TACO (PROENçA; SIMõES, 2020) e ajustado com cerca de 100 fotos da equipe, divididas aleatoriamente em 80% para treino e 20% para validação (SANTOS; COSTA, 2025). Antes do ajuste, o melhor modelo atingia mAP@0,5 médio de 0,565 nas fotos da equipe. Após o ajuste, as métricas de validação chegam a mAP@0,5 de 0,80, e a 0,995 na última versão dos pesos. Esses valores, porém, são otimistas: as fotos retratam as mesmas cenas em quatro condições de captura, tiradas com segundos de diferença, e uma divisão aleatória por imagem coloca a mesma cena no treino e na validação. Não há, portanto, uma estimativa confiável do desempenho em resíduos novos, nem medição do sistema completo (taxa de separação correta). O novo modelo deve ser avaliado de forma que essas duas lacunas sejam fechadas (Seção 5.3.5).

5.3.2 Taxonomia Hierárquica de Classes

O modelo anterior prevê 61 classes do TACO, convertidas em material por uma tabela no código. Essa abordagem tem dois problemas: a maioria das classes do TACO nunca aparece na esteira, e classes de material misto ficam sem destino. Por outro lado, prever apenas os quatro materiais descarta informação útil para a cooperativa, já que objetos do mesmo material podem ter valores de venda e destinos diferentes.

Adotamos, portanto, uma taxonomia hierárquica (JR.; FREITAS, 2011) de dois níveis:

Tabela 4 – Requisitos funcionais.

ID	**Descrição**
Operação	
RF01	O sistema deve detectar e classificar, em tempo real, os resíduos que passam pela região observada da esteira, segundo a taxonomia hierárquica da Seção 5.3.2.
RF02	O sistema deve rastrear cada objeto entre quadros e atribuir a ele um identificador único, acionando o desviador no máximo uma vez por objeto.
RF03	O sistema deve acionar o desviador no instante em que o objeto alcança o ponto de desvio, calculado a partir da posição do objeto, da velocidade da esteira e da distância até o desviador.
RF04	O sistema deve permitir ligar e desligar a esteira pela interface.
RF05	O sistema deve aplicar, sem reinicialização, as alterações de limiar de confiança e de ângulos do desviador feitas pela interface.
RF06	O sistema deve continuar detectando e exibindo o vídeo sem a conexão com o microcontrolador (modo de demonstração) e indicar esse estado na interface.
Registro e monitoramento	
RF07	O sistema deve registrar cada objeto detectado, com identificador, classe, material, confiança, horário, decisão de acionamento e versão do modelo.
RF08	O sistema deve exibir o histórico de resíduos processados, com totais por material e por período.
RF09	O sistema deve registrar a latência de cada etapa (captura, inferência, decisão, envio do comando).
Coleta e anotação	
RF10	O sistema deve selecionar quadros para anotação durante a operação, priorizando objetos de baixa confiança, divergências entre o detector e o anotador automático e classes pouco representadas, e evitando quadros quase idênticos do mesmo objeto.
RF11	O sistema deve gerar pré-anotações (caixas e rótulos) para os quadros selecionados com um anotador automático de vocabulário aberto.
RF12	O sistema deve oferecer uma interface de revisão em que o revisor aceita, corrige ou descarta cada pré-anotação e adiciona objetos não detectados.
RF13	O sistema deve registrar o tempo de revisão de cada imagem e as correções feitas sobre as pré-anotações.
RF14	O sistema deve permitir cadastrar novas classes na taxonomia, sob uma classe de material existente.
Retreinamento e implantação	
RF15	O sistema deve treinar um novo modelo a partir da base incremental, sob comando do administrador, sem interromper a operação.
RF16	O sistema deve avaliar cada novo modelo no conjunto de teste fixo e apresentar a comparação com o modelo em uso.
RF17	O sistema deve manter o histórico de versões de modelos, com os dados e parâmetros de treino de cada uma, e permitir voltar a uma versão anterior.

Tabela 5 – Requisitos não funcionais.

ID	Descrição
RNF01	**Desempenho:** o detector deve processar o vídeo a pelo menos [**a definir**] quadros por segundo no computador do protótipo, o suficiente para que cada objeto apareça em vários quadros dentro da região observada.
RNF02	**Latência:** o tempo entre a captura do quadro e o envio do comando ao desviador deve ser menor que a margem dada pela distância até o desviador e pela velocidade da esteira ([**a definir**] ms).
RNF03	**Precisão:** o detector deve atingir mAP@0,5 de pelo menos [**a definir**] no nível de material, medido no conjunto de teste fixo (Seção 5.3.5).
RNF04	**Não regressão:** um novo modelo só pode ser implantado se não piorar o mAP no conjunto de teste fixo em relação ao modelo em uso.
RNF05	**Custo:** o sistema deve operar com hardware de baixo custo (computador sem GPU dedicada ou com GPU de entrada, webcam, ESP32); o retreinamento e a anotação automática podem usar um computador com GPU separado da operação.
RNF06	**Confiabilidade:** falhas da câmera ou da porta serial não devem encerrar o sistema; ele deve tentar reconectar e indicar a falha na interface. A comunicação serial deve ser protegida contra acesso concorrente.
RNF07	**Reprodutibilidade:** os scripts de treino, as divisões treino/validação/teste e as configurações de cada versão de modelo devem ser versionados junto ao código.
RNF08	**Usabilidade:** a interface de revisão deve permitir revisar uma imagem com poucas ações, de modo que o tempo de revisão seja menor que o de anotação manual.
RNF09	**Privacidade:** as imagens armazenadas devem se restringir à região da esteira, evitando registrar pessoas, em conformidade com a LGPD.
RNF10	**Armazenamento:** imagens e pesos de modelo não devem ser versionados diretamente no repositório de código, e sim em armazenamento próprio para dados.

- **Nível 1 (material):** plástico, metal, vidro, papel e rejeito. É o nível que decide o acionamento do desviador;

- **Nível 2 (tipo de objeto):** por exemplo, garrafa PET, tampa plástica e filme plástico, sob plástico; lata de bebida, sob metal; garrafa de vidro, sob vidro; papelão ondulado e papel comum, sob papel. Esse nível alimenta o histórico de resíduos e pode crescer ao longo dos ciclos (RF14).

O detector é treinado sobre as classes do nível 2 (as folhas da taxonomia), e o material é obtido pela classe-pai. Quando a confiança na classe do nível 2 é baixa, mas a soma das confianças das classes de um mesmo material é alta, o sistema atribui apenas o nível 1, o que basta para o acionamento. Assim, novas classes podem ser adicionadas sem alterar a lógica de controle, e um objeto de tipo desconhecido ainda pode ser desviado corretamente se o seu material for reconhecido. A taxonomia inicial parte das seis classes da base anterior e das classes do TACO que de fato ocorrem na esteira.

5.3.3 Escolha do Detector

A arquitetura do detector em operação fica em aberto nesta especificação e será escolhida por comparação experimental. Como linha de base, usamos o YOLOv8s do projeto anterior (REDMON et al., 2016). Entre os candidatos estão versões mais recentes da família YOLO, como o YOLO11 (JOCHER; QIU, 2024), e detectores baseados em *transformers* voltados a tempo real, como o RT-DETR (ZHAO et al., 2024). Os critérios de escolha são:

1. mAP no conjunto de teste fixo, no nível de material e no nível de tipo de objeto;
2. latência de inferência no computador do protótipo, que deve atender aos RNF01 e RNF02;
3. custo de cada ciclo de retreinamento (tempo e memória de GPU), já que o modelo é retreinado repetidamente;
4. compatibilidade com o rastreamento de objetos (RF02) e com exportação para formatos otimizados de inferência;
5. licença de uso. As implementações da Ultralytics são distribuídas sob a licença AGPL-3.0, o que deve ser considerado caso o sistema seja distribuído a terceiros.

O rastreamento de objetos (RF02) é feito sobre as detecções, por um rastreador do tipo *tracking-by-detection*, como o ByteTrack (ZHANG et al., 2022), independentemente da arquitetura escolhida. Ele resolve as detecções múltiplas de um mesmo resíduo, apontadas como limitação do projeto anterior, e permite estimar a posição e a velocidade de cada objeto para o controle de acionamento (RF03).

5.3.4 Anotação Assistida

A anotação assistida usa um anotador automático de vocabulário aberto, que não depende do detector em operação e, por isso, não herda os seus erros. Propomos a combinação de dois modelos:

- **Grounding DINO (LIU et al., 2024):** detector de vocabulário aberto que localiza objetos a partir de descrições em texto. As descrições são geradas a partir das classes do nível 2 da taxonomia (por exemplo, "*plastic bottle*", "*aluminium can*"), de modo que uma nova classe cadastrada passa a ser anotada sem treino adicional;
- **Segment Anything (SAM) (KIRILLOV et al., 2023):** modelo de segmentação que, a partir das caixas propostas, produz máscaras do objeto. As máscaras permitem ajustar as caixas aos contornos reais e servem para separar objetos sobrepostos.

Esses modelos são mais lentos que o detector em operação, mas isso não é uma restrição, pois a anotação ocorre fora do laço de tempo real, possivelmente num computador separado (RNF05). O revisor humano continua responsável pelo rótulo final (MONARCH, 2021). Para que o ganho da anotação assistida seja mensurável (objetivo 3), registramos, para cada imagem, o tempo de revisão e a diferença entre a pré-anotação e a anotação final (RF13). Com isso, calculamos a precisão e o recall do anotador automático, tomando a anotação revisada como referência, e a redução do tempo de anotação em relação à anotação manual de um mesmo conjunto de imagens.

A seleção dos quadros a anotar (RF10) segue estratégias de aprendizado ativo (SETTLES, 2010; REN et al., 2021): priorizar quadros em que o detector tem baixa confiança, em que o detector e o anotador automático discordam ou em que aparecem classes raras. O rastreamento evita anotar dezenas de quadros quase idênticos do mesmo objeto: de cada objeto rastreado é selecionado no máximo um quadro, o de maior incerteza.

Um risco dessa abordagem é o viés de automação: o revisor tende a aceitar as pré-anotações sem examiná-las. Para medi-lo, uma amostra das imagens é anotada manualmente, sem pré-anotação, e comparada às revisadas.

5.3.5 Protocolo de Avaliação

O protocolo de avaliação corrige o vazamento de dados do projeto anterior e acompanha o modelo ao longo dos ciclos (objetivo 4):

- **Divisão por sessão:** quadros de vídeo consecutivos são quase idênticos, então treino, validação e teste são divididos por sessão de captura (um dia ou um lote de resíduos), e nunca por imagem. Nenhum objeto físico aparece em mais de uma divisão;
- **Conjunto de teste fixo:** um conjunto de teste é anotado manualmente no início do trabalho e congelado. Todos os modelos, inclusive a linha de base do projeto anterior, são avaliados nele, o que torna os ciclos comparáveis entre si. A cada ciclo, avalia-se também um conjunto de teste novo, com dados das sessões mais recentes, para detectar mudanças na composição dos resíduos;
- **Métricas do modelo:** mAP@0,5 e mAP@0,5:0,95, e precisão e recall por classe no limiar de confiança usado em operação, nos dois níveis da taxonomia. A precisão média isolada não é usada como critério, pois classes sem nenhuma detecção correta a inflam;
- **Métricas do sistema:** taxa de separação correta por material, obtida passando pela esteira um número conhecido de objetos de cada material, taxa de acionamentos indevidos e latência de ponta a ponta;

- **Métricas do ciclo:** evolução do mAP no conjunto de teste fixo a cada ciclo, em função do número de imagens anotadas e do tempo de revisão gasto.

6 Implementação

[PENDENTE: Escrever]

7 Resultados

[PENDENTE: Escrever]

8 Conclusões

[PENDENTE: Escrever]

Referências

ABREMA. *Panorama dos Resíduos Sólidos no Brasil 2025*. São Paulo, 2025. Dados referentes a 2024. Disponível em: <https://www.abrema.org.br/panorama/>. Citado 2 vezes nas páginas 13 e 17.

BASHKIROVA, D. et al. ZeroWaste dataset: Towards deformable object segmentation in cluttered scenes. In: *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*. [S.l.: s.n.], 2022. PENDENTE: lista completa de autores e páginas. Citado na página 14.

Brasil. *Lei nº 12.305, de 2 de agosto de 2010. Institui a Política Nacional de Resíduos Sólidos*. 2010. Diário Oficial da União. Disponível em: <https://www.planalto.gov.br/ccivil_03/_ato2007-2010/2010/lei/l12305.htm>. Citado 2 vezes nas páginas 13 e 17.

FENG, C. et al. TOOD: Task-aligned one-stage object detection. In: *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*. [S.l.: s.n.], 2021. Citado na página 20.

GOODFELLOW, I.; BENGIO, Y.; COURVILLE, A. *Deep Learning*. [S.l.]: MIT Press, 2016. Citado 2 vezes nas páginas 19 e 20.

GUNDUPALLI, S. P.; HAIT, S.; THAKUR, A. A review on automated sorting of source-separated municipal solid waste for recycling. *Waste Management*, v. 60, 2017. Citado 2 vezes nas páginas 14 e 18.

Instituto Caminhos Sustentáveis. *Anuário da Reciclagem 2024*. [S.l.], 2024. Apoio: Sebrae e Sistema OCB. Disponível em: <https://www.anuariodareciclagem.eco.br/>. Citado 3 vezes nas páginas 13, 14 e 17.

IOFFE, S.; SZEGEDY, C. Batch normalization: Accelerating deep network training by reducing internal covariate shift. In: *International Conference on Machine Learning (ICML)*. [S.l.: s.n.], 2015. Citado na página 20.

JOCHER, G. et al. *Ultralytics YOLO*. Disponível em: <https://github.com/ultralytics/ultralytics>. Citado na página 20.

JOCHER, G.; QIU, J. *Ultralytics YOLO11*. 2024. <https://github.com/ultralytics/ultralytics>. Licença AGPL-3.0. Citado na página 34.

JR., C. N. S.; FREITAS, A. A. A survey of hierarchical classification across different application domains. *Data Mining and Knowledge Discovery*, v. 22, n. 1–2, p. 31–72, 2011. Citado na página 31.

KIRILLOV, A. et al. Segment anything. In: *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*. [S.l.: s.n.], 2023. p. 4015–4026. Citado na página 34.

LECUN, Y. et al. Gradient-based learning applied to document recognition. *Proceedings of the IEEE*, v. 86, n. 11, p. 2278–2324, 1998. Citado na página 19.

LI, X. et al. Generalized focal loss: Learning qualified and distributed bounding boxes for dense object detection. In: *Advances in Neural Information Processing Systems (NeurIPS)*. [S.l.: s.n.], 2020. Citado na página 20.

LIN, T.-Y. et al. Focal loss for dense object detection. In: *Proceedings of the IEEE International Conference on Computer Vision (ICCV)*. [S.l.: s.n.], 2017. Citado na página 20.

LIN, T.-Y. et al. Microsoft COCO: Common objects in context. In: *European Conference on Computer Vision (ECCV)*. [S.l.: s.n.], 2014. Citado na página 20.

LIU, S. et al. Grounding DINO: Marrying DINO with grounded pre-training for open-set object detection. In: *Computer Vision – ECCV 2024*. [S.l.: s.n.], 2024. ArXiv:2303.05499. Citado na página 34.

LIU, W. et al. SSD: Single shot multibox detector. In: *European Conference on Computer Vision (ECCV)*. [S.l.: s.n.], 2016. Citado na página 20.

LU, W.; CHEN, J. Computer vision for solid waste sorting: A critical review of academic research. *Waste Management*, v. 142, 2022. Citado na página 14.

MONARCH, R. M. *Human-in-the-Loop Machine Learning*. [S.l.]: Manning, 2021. Citado 2 vezes nas páginas 14 e 35.

PROENçA, P. F.; SIMõES, P. *TACO: Trash Annotations in Context for Litter Detection*. 2020. Citado 2 vezes nas páginas 14 e 31.

REDMON, J. et al. You only look once: Unified, real-time object detection. In: *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*. [S.l.: s.n.], 2016. p. 779–788. Citado 3 vezes nas páginas 14, 20 e 34.

REN, P. et al. A survey of deep active learning. *ACM Computing Surveys*, v. 54, n. 9, 2021. Citado 2 vezes nas páginas 14 e 35.

REN, S. et al. Faster R-CNN: Towards real-time object detection with region proposal networks. In: *Advances in Neural Information Processing Systems (NeurIPS)*. [S.l.: s.n.], 2015. v. 28. Citado na página 20.

SANTOS, N. F. M.; COSTA, V. S. *EcoVision: Automação Inteligente de Coleta Seletiva*. 2025. Citado 5 vezes nas páginas 13, 15, 23, 24 e 31.

SETTLES, B. *Active Learning Literature Survey*. [S.l.], 2010. Citado 2 vezes nas páginas 14 e 35.

SZELISKI, R. *Computer Vision: Algorithms and Applications*. 2. ed. [S.l.]: Springer, 2022. Citado na página 19.

TOMRA. 2026. Disponível em: <https://www.tomra.com/waste-metal-recycling/products/machines>. Citado na página 14.

WANG, C.-Y. et al. CSPNet: A new backbone that can enhance learning capability of CNN. In: *IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops (CVPRW)*. [S.l.: s.n.], 2020. Citado na página 20.

YANG, M.; THUNG, G. *Classification of Trash for Recyclability Status*. [S.l.], 2016. Citado na página 14.

ZHANG, Y. et al. ByteTrack: Multi-object tracking by associating every detection box. In: *Computer Vision – ECCV 2022*. [S.l.: s.n.], 2022. p. 1–21. Citado na página 34.

ZHAO, Y. et al. DETRs beat YOLOs on real-time object detection. In: *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*. [S.l.: s.n.], 2024. p. 16965–16974. Citado na página 34.

ZHENG, Z. et al. Distance-IoU loss: Faster and better learning for bounding box regression. In: *Proceedings of the AAAI Conference on Artificial Intelligence*. [S.l.: s.n.], 2020. Citado na página 20.